

Approximation of Softmax with MBE Neurons

Softmax 함수

$$\text{Softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

여기서 x_i 는 입력 벡터의 i 번째 요소이며, 분모는 모든 입력 요소에 대한 지수 함수 값의 합이다.

MBE 뉴런을 이용한 소프트맥스 근사화

소프트맥스를 근사하기 위해 논문에서는 이를 **지수 함수(e^x)**, **역수($1/x$)**, 그리고 **부동소수점 곱셈(FP multiplication)**이라는 세 가지 주요 구성 요소로 분해하고, 각 구성 요소를 MBE 뉴런으로 근사한다.

1. 지수 함수 (e^{x_i}) 근사:

e^{x_i} 를 직접적으로 스파이크 기반으로 근사하는 것은 어렵기에, 밑 변경 공식을 사용하여 밑이 2인 식으로 바꾼다.

$$e^{x_i} = 2^{x_i \cdot \log_2 e}$$

이를 정수 부분과 소수 부분으로 나눈다.

$$e^{x_i} = 2^{\lfloor x_i \cdot \log_2 e \rfloor} \cdot 2^{x_i \cdot \log_2 e - \lfloor x_i \cdot \log_2 e \rfloor}$$

- 정수 부분 ($2^{\lfloor x_i \cdot \log_2 e \rfloor}$): $\lfloor x_i \cdot \log_2 e \rfloor$ 는 정수다. 2의 정수 거듭제곱은 하드웨어적으로 효율적인 **덧셈 연산(shift operation)**으로 구현될 수 있다.
- 소수 부분 ($2^{x_i \cdot \log_2 e - \lfloor x_i \cdot \log_2 e \rfloor}$): 이 지수 부분은 0과 1 사이의 실수 값을 가진다. 이 '지수' 자체의 근사를 MBE 뉴런으로 수행한다. 즉, MBE 뉴런은 입력값 $y = x_i \cdot \log_2 e - \lfloor x_i \cdot \log_2 e \rfloor$ 를 받아, 2^y 값을 근사하도록 학습되거나 설계된다. 이 두 부분을 결합하여 $e^{\lfloor x_i \rfloor} e^{x_i - \lfloor x_i \rfloor}$ 를 근사한다.

2. 역수 ($\frac{1}{\sum e^{x_j}}$) 근사:

IEEE 754 부동소수점 표준을 활용하여 역수를 근사한다.

- 먼저, $\sum e^{x_j}$ 의 값을 부동소수점 형식으로 표현했을 때, 이를 지수(Exponent, E)와 가수(Mantissa, M) 부분으로 분리한다. 즉, $\sum e^{x_j} = M \cdot 2^E$ 와 같이 표현한다.
- $\frac{1}{M}$ 근사: 가수의 역수 $\frac{1}{M}$ 은 MBE 뉴런을 사용하여 직접 근사한다. MBE 뉴런은 M 값을 입력받아 $\frac{1}{M}$ 값을 스파이크 기반으로 복원하도록 설계된다.
- 최종 역수 계산: 역수 $\frac{1}{\sum e^{x_j}}$ 은 $2^{-E}/M$ 과 같이 계산된다. 여기서 2^{-E} 는 지수 연산으로, $-E$ 가 정수이므로 하드웨어적으로 효율적인 덧셈(shift)으로 처리할 수 있다. $\frac{1}{M}$ 부분은

MBE 뉴런이 근사하므로, 이 두 결과를 결합하면 소프트맥스 분모의 역수를 스파이크 기반으로 얻을 수 있다.

3. FP 곱셈 활용:

- 소프트맥스의 최종 결과는 $\text{Softmax}(x_i) = e^{x_i} \cdot \frac{1}{\sum e^{x_j}}$ 로 볼 수 있다.
- 여기서 e^{x_i} 는 위에서 설명한 방식으로 근사되고, $\frac{1}{\sum e^{x_j}}$ 도 근사된다.
- 이 두 근사된 값들을 곱하는 연산에는 MBE 뉴런을 사용한 FP 곱셈 근사 방법이 적용된다.

의의

이러한 단계들을 통해, 소프트맥스 함수 계산의 각 비-스�파이크 친화적인 부분(지수, 역수, 곱셈)이 MBE 뉴런 기반의 스파이크 기반 연산으로 대체된다. 결과적으로, 소프트맥스 연산 전체가 스파이크 신호를 통해 계산되어, SNN 모델에서 효율적으로 처리될 수 있게 된다.