

차세대 스파이킹 트랜스포머(Spiking Transformer)를 위한 동적 연산 에너지(Dynamic Compute Energy) 측정 모델 및 Extended-Adaptive MBE 뉴런 기반의 효율성 최적화 심층 분석

1. 서론: 대규모 인공지능 모델의 에너지 장벽과 스파이킹 매핑 패러다임

현대 인공지능 기술이 대규모 언어 모델(Large Language Models, LLMs) 및 비전-언어 모델(Vision-Language Models, VLMs)로 진화함에 따라, 폰 노이만(von Neumann) 아키텍처 기반의 하드웨어 연산 장치들이 요구하는 전력 소모와 메모리 대역폭은 물리적, 경제적 한계에 직면하고 있다. 수천억 개의 파라미터를 지닌 트랜스포머(Transformer) 아키텍처를 추론(Inference) 단계에서 구동하기 위해서는 막대한 양의 부동소수점 곱셈-덧셈(Multiply-Accumulate, MAC) 연산이 필수적이며, 이는 엣지 디바이스(Edge Device) 및 전력 제한적 환경에서의 인공지능 도입을 가로막는 가장 큰 병목으로 작용한다. 이러한 전력 소모의 한계를 극복하기 위해, 생물학적 뇌의 신경망 작동 방식을 모방한 3세대 인공신경망인 스파이킹 신경망(Spiking Neural Networks, SNNs)이 학술적, 산업적 대안으로 급부상하고 있다.

SNN은 연속적인 실수(Floating-point) 값을 전달하는 기존 인공 신경망(Artificial Neural Networks, ANNs)과 달리, 시간이산적(Time-discrete)이고 희소한(Sparse) 이진 스파이크(Binary spikes, $\{0, 1\}$) 형태로 정보를 인코딩하고 전달한다. 이러한 이벤트 구동(Event-driven) 특성은 하드웨어 레벨에서 전력 소모가 극심한 부동소수점 곱셈 연산을 제거하고, 스파이크가 발생할 때만 활성화되는 단순한 덧셈 연산(Accumulate, AC 또는 Synaptic Operation, SOP)으로 치환할 수 있게 하여 뉴로모픽 칩 환경에서 압도적인 에너지 효율을 제공하는 것으로 알려져 있다.

최근의 SNN 연구는 단순한 다층 퍼셉트론(MLP)이나 합성곱 신경망(CNN)을 넘어, 자연어 처리와 컴퓨터 비전을 통합적으로 다루는 트랜스포머 아키텍처를 스파이크 도메인으로 이식하는 데 집중되고 있다. 대규모 트랜스포머 모델을 SNN으로 구축하는 주류 방법론은 사전에 훈련된 고성능 ANN의 가중치를 SNN으로 복사한 뒤, 뉴런의 동역학을 조절하여 활성화 함수를 근사하는 '훈련 없는(Training-Free) ANN-to-SNN (A2S) 변환' 방식이다. 이는 대리 기울기(Surrogate Gradient) 기법을 사용하는 직접 학습(Direct Training)이 수반하는 막대한 메모리 오버헤드와 기울기 근사 오차를 원천적으로 제거할 수 있다는 강력한 이점을 지닌다. 최근 현재 진행 중인 MLP2SNN 연구에서도 MLP를 Training-Free 방식으로 SNN 변환했을 때 정확도 하락이 0.5% 이내로 방어되며 성능이 유지된다는 점이 실증적으로 확인되었다.

그러나 이러한 학술적 진보의 이면에는, 변환된 SNN 모델들의 '정확한 전력 소모 측정 모델의 부재'라는 치명적인 맹점이 존재한다. 현재 세계 최상위 인공지능 학회(AAAI, NeurIPS, ICML 등)에서 발표되는 대부분의 SNN 논문들은 효율성을 검증할 때 단지 모델 내부의 MAC 연산 수와 AC 연산 수를 산출한 뒤, 특정 하드웨어 기술(예: 45nm CMOS)의 고정 에너지 상수(MAC = 4.6~4.7 pJ, AC = 0.9 pJ)를 단순히 곱하여 비교하는 1차원적인 지표만을 사

용하고 있다. 이는 트랜스포머 아키텍처의 핵심인 비선형 활성화 함수(GELU), 어텐션(Attention) 기법, 정규화(LayerNormalization) 연산에 내재된 복잡한 지수, 나눗셈, 제곱근 연산의 극심한 에너지 비용을 완전히 무시한 처사이다. 더불어, 이러한 비선형 연산들을 스파이크 도메인으로 억지로 근사하려 할 때 파생되는 폭발적인 SOP 연산량의 증가는 SNN의 효율성을 오히려 ANN보다 악화시키는 역효과를 낳기도 한다.

본 심층 연구 보고서는 현재 A2S 변환 및 스파이킹 트랜스포머 연구에서 통용되는 MAC/AC 기반 효율성 지표의 이론적, 하드웨어적 오류를 비판적으로 해체하고, 최신 베이스 논문(AAAI-26)이 제시한 다중 기저 지수 감쇠(MBE) 뉴런의 수학적 한계와 구조적 모순을 명확히 규명한다. 이를 바탕으로, 본 연구진이 새롭게 제안한 '**Extended-Adaptive MBE 뉴런**' 구조를 도입하여 데드 뉴런(Dead Neuron) 현상을 근원적으로 타개하는 방안을 제시한다. 나아가 선형 연산(Linear layer)의 부동소수점 곱셈을 MBE 뉴런의 효과적 가중치(W_{eff}) 기반 조건부 덧셈으로 최적화한 알고리즘을 분석하며, 하드웨어 종속적인 메모리 계층(Memory Hierarchy) 이동 비용을 제외한 순수 동적 연산 에너지(Dynamic Compute Energy)만을 기준으로 ANN과 SNN의 구조적 특성을 완벽히 반영한 새롭고 정확한 전력 소모 측정 모델(Comprehensive Dynamic Compute Efficiency Ratio, CDCER)을 제안한다.

2. 기존 SNN 효율성 지표의 근본적 오류와 탐티어 연구 동향 분석

2.1 Horowitz 45nm CMOS 연산 에너지 상수의 기원과 MAC/AC 비교의 함정

현재 SNN 문헌에서 효율성을 입증하기 위해 절대적인 기준으로 인용되는 에너지 상수는 Mark Horowitz 교수가 2014년 ISSCC(International Solid-State Circuits Conference)에서 발표한 45nm CMOS 공정 기반의 연산별 에너지 소모량 지표에 뿌리를 두고 있다. 해당 연구에 따르면, 45nm 공정에서 32비트 정수 덧셈은 0.1 pJ, 32비트 부동소수점 덧셈(FP Add)은 0.9 pJ, 32비트 부동소수점 곱셈(FP Mult)은 3.7 pJ의 동적 에너지를 소모한다. 기존 ANN의 핵심 연산 단위인 MAC(Multiply-Accumulate)은 한 번의 곱셈과 한 번의 덧셈이 결합된 연산이므로, 총 에너지 비용은 $3.7 + 0.9 = 4.6$ pJ (혹은 칩 구조에 따라 4.7 pJ)로 계산된다. 반면, SNN은 이진 스파이크 입력을 받기 때문에 가중치를 누적하는 연산(AC)만이 발생하며, 이는 부동소수점 덧셈 1회에 해당하므로 0.9 pJ의 에너지가 소모된다고 간주한다.

이러한 수치적 배경을 바탕으로, AAAI, NeurIPS, ICML 등 탐티어 학회에 게재된 대부분의 SNN 연구들은 다음의 공식을 활용하여 SNN의 우월성을 주장해왔다.

$$E_{Ratio} = \frac{E_{SNN}}{E_{ANN}} = \frac{N_{SOP} \times 0.9 \text{ pJ}}{N_{MAC} \times 4.6 \text{ pJ}}$$

이 공식은 전통적인 합성곱 신경망(CNN) 기반의 비전 모델(VGG, ResNet 등)에서는 어느 정도 유효한 지표로 기능했다. CNN은 전체 연산의 90% 이상이 합성곱 계층에서의 내적(Dot-product) 연산으로 이루어지며, 활성화 함수 역시 단순히 음수를 0으로 치환하는 ReLU 함수를 사용하여 비선형 연산에 소모되는 추가 에너지가 극히 미미했기 때문이다. 그러나 트랜스포머와 같은 3세대 대규모 신경망 모델로 넘어오면서 이 공식을 적용하는 것은 명백한 통계적, 공학적 왜곡이다. 트랜스포머 아키텍처는 모델 내부에 다변수 비선형 연산들이 조밀하게 얹혀 있으며, 이들은 단순한 덧셈과 곱셈 연산기(ALU)만으로는 결코 처리할 수 없는 고비용의 하드웨어 블록을 요구한다.

2.2 트랜스포머 내 비선형 연산의 숨겨진 하드웨어 오버헤드

최신 트랜스포머 기반 모델(Vision Transformer, LLM 등)은 GELU 활성화 함수, 어텐션 스코어 산출을 위한 Softmax, 학습 안정성을 위한 LayerNormalization과 같은 복잡한 비선형 연산을 필수적으로 수반한다. 이러한 연산들은 하드웨어 관점에서 단순히 MAC 단위로 환산될 수 없는 막대한 동적 에너지를 소모한다.

- GELU (Gaussian Error Linear Unit):** 트랜스포머의 다층 퍼셉트론(MLP) 블록에 주로 사용되는 GELU는 $f(x) = x\Phi(x)$ 로 정의되며, 이를 근사 수식으로 표현하면 $0.5x(1 + \tanh(\sqrt{2/\pi}(x + 0.044715x^3)))$ 이 된다. 이 수식을 처리하기 위해서는 단순히 MAC을 반복하는 것을 넘어, 지수 연산 기반의 쌍곡선 탄젠트(tanh)와 제곱, 세제곱 등 다양한 다항식 연산이 요구된다. 지수 함수(e^x)의 하드웨어 처리는 테일러 급수(Taylor Series) 전개나 CORDIC 알고리즘을 통한 다수의 순차적 내적 계산을 수반하며, 그 에너지 비용은 일반적인 부동소수점 덧셈의 수십 배에 달한다.
- Softmax 연산:** 어텐션 맵을 확률 분포로 변환하는 Softmax 연산은 $\text{Softmax}(x_i) = \frac{\exp(x_i)}{\sum_j \exp(x_j)}$ 로 표현된다. 이는 모든 입력 채널에 대한 연속적인 지수 함수(exp) 연산뿐만 아니라, 합산된 값을 다시 각각의 요소에 나누어주는 부동소수점 나눗셈(Floating-Point Division) 연산을 포함한다. 하드웨어 레벨에서 나눗셈은 SRT(Sweeney, Robertson, and Tocher) 알고리즘이나 뉴턴-랩슨(Newton-Raphson) 근사법을 사용하여 파이프라인의 여러 사이클을 점유하며, 단일 MAC 연산 대비 10~15배 이상의 전력을 소모하는 매우 값비싼 연산이다.
- Layer Normalization:** 정규화 계층은 입력 텐서의 평균(μ)과 분산(σ^2)을 구한 뒤, 이를 바탕으로 $\text{LayerNorm}(x) = \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} \cdot \gamma + \beta$ 연산을 수행한다. 여기서 가장 치명적인 연산 병목은 역제곱근(Inverse Square Root, $1/\sqrt{x}$)이다. 고속의 부동소수점 역제곱근을 도출하기 위해서는 복잡한 근사 알고리즘과 곱셈기, 시프터(Shifter)들이 혼합된 전용 하드웨어 유닛이 필요하며, 이 또한 MAC 대비 압도적인 동적 컴퓨팅 에너지를 소모한다.

기존 SNN 논문들이 효율성을 비교할 때 $N_{MAC} \times 4.6 \text{ pJ}$ 만으로 ANN의 에너지를 산출하는 것은, 위와 같은 수많은 나눗셈, 지수, 제곱근 연산이 소비하는 에너지를 '0'으로 간주하는 것과 같다. 반대로 SNN은 이러한 비선형 함수를 여러 타임스텝에 걸쳐 스파이크의 발화율(Firing rate)로 근사하기 위해 막대한 양의 누적 연산(SOP)을 발생시킨다. 결국 비용이 축소 산정된 ANN과 모든 근사 과정이 누적된 SNN을 비교하는 현재의 지표는 학술적으로 효력을 가질 수 없으며, 이러한 관행이 지속될 경우 SNN의 실제 에너지 절감 잠재력은 심각하게 왜곡될 수밖에 없다.

2.3 탐티어 학회 연구들의 한계와 비판적 교차 검증

최근 국제 최상위 인공지능 학회(AAAI, NeurIPS, ICML 등)에서는 트랜스포머의 비선형성을 SNN으로 매핑하기 위한 다양한 시도가 발표되고 있으나, 연산의 복잡도와 에너지 측정 측면에서 여전히 구조적 결함을 안고 있다.

- NeurIPS 2024의 SpikedAttention 프레임워크:** 해당 연구는 트랜스포머의 어텐션 구조를 스파이크 기반으로 성공적으로 이식했다고 주장하였으나, 복잡도가 가장 높은 LayerNorm과 Softmax 연산의 일부를 여전히 비-스파이킹(Non-spiking) 부동소수점 연

산으로 남겨두는 타협을 선택했다. 이는 전체 신경망의 순수 이벤트 구동(Event-driven) 특성을 파괴할 뿐만 아니라, 중간 활성화 값들을 다시 부동소수점으로 변환하기 위한 ADC/DAC 하드웨어 오버헤드를 발생시켜 에너지 효율의 허상을 초래한다.

- **ICML 2025의 Differential Coding 기법:** 차분 코딩을 통해 잔차 연결(Residual connection)에서 발생하는 오차를 교정하려는 이 연구는 부호 있는 뉴런(Signed Neuron)의 필요성을 역설했다. 이는 곧 양방향 발화가 불가능한 기존의 스파이킹 뉴런 모델로는 정규화 계층이나 GELU의 오차를 잡을 수 없음을 반증하는 강력한 논거가 된다.
- **AAAI-26 베이스 논문의 MBE 프레임워크:** 본 연구의 직접적인 분석 대상인 베이스 논문(Training-Free ANN-to-SNN Conversion for High-Performance Spiking Transformers)은 IEEE 754 표준을 응용한 지수 및 가수 분해 기법으로 비선형 연산의 매핑을 시도하였다. 수식적 간결성은 확보하였으나, 여전히 에너지 평가 시 $E_{MAC} = 4.6 \text{ pJ}$ 와 $E_{AC} = 0.9 \text{ pJ}$ 만을 대입하는 과거의 방식을 답습하여, 비선형 변환 과정에서 파생된 복잡한 스파이크 상호작용의 에너지 비용을 제대로 투영하지 못했다.

이러한 탐티어 연구들의 공통된 맹점은, A2S 변환 후의 성능 하락률(예: 0.5% 성능 하락 방어)에만 집착한 나머지, 하드웨어에서 실제로 연산이 구동될 때 발생하는 소자 수준의 동적 에너지 발산(Dynamic Energy Dissipation)을 외면했다는 데 있다. SNN이 진정한 의미의 초저전력 인공지능 솔루션으로 인정받기 위해서는, 연산의 '종류'와 '양'을 모두 세분화하여 측정할 수 있는 새로운 아키텍처 매핑 모델과 동역학적 측정 기준이 필수적이다.

3. 베이스 논문(AAAI-26 MBE 뉴런)의 구조 분석 및 수학적 결합 증명

현재 진행 중인 연구의 근간이 되는 AAAI-26 베이스 논문은 트랜스포머 내부의 다변수 비선형 연산들을 가중치 미세 조정 없이 스파이크 도메인으로 매핑하기 위해 **다중 기저 지수 감쇠(Multi-basis Exponential Decay, MBE) 뉴런**을 도입하였다. 이 뉴런 구조는 표면적으로 매우 혁신적인 접근으로 보이나, 트랜스포머의 비선형 곡선을 근사하는 데 있어 치명적인 수학적 모순을 내포하고 있다.

3.1 전통적 Few-Spikes (FS) 뉴런의 근사 한계

MBE 뉴런의 등장을 이해하기 위해서는 그 전신인 Few-Spikes (FS) 뉴런의 한계를 파악해야 한다. FS 뉴런은 스파이크 발생 타이밍과 패턴을 통해 신경 활성화 상태를 표현하며, 발화 임계값(V_{th}), 막전위 리셋값(r), 스파이크 강도(d)를 타임스텝별로 학습 가능한 독립 파라미터로 두어 타겟 활성화 함수를 근사하고자 했다.

베이스 논문은 FS 뉴런의 근사 오차 상한(Error Bound)을 다음과 같은 수학적 정리(Theorem 1)로 증명하였다. $\epsilon \leq \mathcal{O} \left(\sqrt{\frac{T \log T \log M}{M}} + \frac{\mathcal{L}_f |y|_{max}}{T} + \frac{\|d\|_1}{T} \right)$

여기서 근사 오차는 세 가지 요소로 분해된다.

1. **경험적 간극 (Empirical Gap):** $\sqrt{\frac{T \log T \log M}{M}}$, 훈련 데이터 샘플링에 의존하는 일반화 오차.

2. **파라메트릭 간극 (Parametric Gap):** $\frac{\mathcal{L}_f|y|_{max}}{T}$, 활성화 함수의 립시츠 상수(Lipschitz constant) $\mathcal{L}_f$ 와 타임스텝 T 에 의해 결정되는 곡률 근사 한계.
3. **양자화 간극 (Quantization Gap):** $\frac{\|d\|_1}{T}$, 스파이크 강도의 이산화에 의해 발생하는 오차.

GELU나 SiLU와 같은 함수는 0 부근에서 극도로 높은 곡률을 가지며 국소적 립시츠 상수($\mathcal{L}_f^{local} \gg \mathcal{L}_f$)가 매우 크다. FS 뉴런의 균일한 시간 할당 방식으로는 이러한 급격한 국소적 오차를 잡아낼 수 없으며, 파라미터 공간이 너무 넓어 무작위 초기화 시 다수의 국소 최솟값(Local Minima)에 빠지는 초기화 과도 의존성(EDI)과 전역적 최적화 실패(GSO) 현상을 야기했다.

3.2 MBE 뉴런의 지수 감쇠 공식과 절대적 양수 제약

이러한 FS 뉴런의 파라미터 최적화 불안정성을 해결하기 위해 베이스 논문은 MBE 뉴런을 제안했다. 매 타임스텝마다 파라미터를 독립적으로 찾는 대신, 파라미터의 변화 궤적을 지수 감쇠(Exponential Decay) 형태의 단일 방정식으로 규제하여 최적화 공간을 대폭 축소한 것이다.

n 번째 기저(Basis) 뉴런의 핵심 동역학은 다음과 같다: $u_n[t+1] = u_n[t] - s_n[t] \cdot r_n[t]$ (막전위 갱신) $s_n[t] = \mathcal{H}(u_n[t] - V_{th_n}[t])$ (스파이크 발화, $\mathcal{H}$ 는 헤비사이드 계단 함수)
 $o_n[t+1] = o_n[t] + s_n[t] \cdot d_n[t]$ (출력 누적)

그리고 핵심 파라미터들(V_{th}, r, d)의 갱신 규칙은 다음과 같이 지수 감쇠 공식으로 통일되었다. $Para(\tau_n, t) = \alpha \cdot \exp\left(-\frac{t\Delta t}{\tau_n}\right)$ 여기서 α 는 스케일링 하이퍼파라미터로 타겟 활성화 함수의 최댓값($|y|_{max}$)으로 설정되며, τ_n 은 학습을 통해 찾아내는 감쇠율(Decay Rate)이다.

하지만 이 수식은 치명적인 수학적 결함을 지니고 있다. 수학적으로 지수 함수 $\exp(x)$ 는 어떠한 실수 범위에서도 항상 양수(> 0)의 값을 반환한다. 또한 파라미터 α 역시 타겟 함수의 치역 내 최대 절댓값으로 고정된 양수(Positive Scaling Parameter)이다. 따라서 양수와 양수의 곱으로 구성된 발화 임계값 $V_{th_n}[t]$ 는 타임스텝 t 가 아무리 진행되어도 0^+ 에 수렴할 뿐, 그 어떠한 시점에서도 절대 0 이하의 음수(Negative)가 될 수 없다 ($V_{th_n}[t] > 0$).

3.3 음수 입력 시나리오에서의 '데드 뉴런(Dead Neuron)' 증명

트랜스포머의 GELU 함수는 입력이 음수일 때(-1.0 근방) 점진적으로 감소하다가 -0.17 부근에서 국소 최솟값을 형성하는 꼬리(Negative Tail)를 지닌다. 이 음수 값은 네트워크 내부에서 특징의 부정적 상관관계를 부각하거나, 어텐션 스코어를 극한으로 낮춰 불필요한 토큰의 개입을 억제하는 핵심 의미 기제(Semantic Mechanism)로 작용한다.

만약 MBE 뉴런에 음수 스칼라 값(예: $x = -1.0$)이 입력된다면 어떤 일이 발생하는가?

1. **초기 상태 ($t = 0$):** 뉴런의 막전위는 입력값인 $u = -1.0$ 이 된다. 발화 임계값 $V_{th_n} = \alpha \cdot 1$ 이며 $\alpha > 0$ 이다. 발화 조건 $u - V_{th} = -1.0 - \alpha < 0$ 이므로 스파이크는 절대 발생하지 않는다 ($s = 0$).
2. **시간의 경과 ($t \geq 1$):** 스파이크가 발생하지 않았으므로 리셋 연산이 생략되며 막전위는 음수 상태(-1.0)를 영구 유지한다. 임계값 $V_{th_n}[t]$ 는 지수적으로 감쇠하지만 수학적 제약으로 인해 영원히 0보다 크다.

3. **연구적 침묵:** 타임스텝 T 내내 $u[t] < 0 < V_{thn}[t]$ 의 부등식이 성립하며, 헤비사이드 계단 함수는 영원히 0만을 반환한다. 뉴런은 단 한 번의 스파이크도 내뿜지 못한 채 '침묵' 상태에 빠지며, 누적 출력은 필연적으로 0이 된다.

이것이 구조적 결함으로 발현된 '**데드 뉴런(Dead Neuron)**' 문제이다. GELU의 음수 출력 (-0.17)이 MBE 뉴런을 거치면서 전부 0으로 평탄화(Flattened)된다. 이 0의 값이 다음 레이어인 Softmax 어텐션으로 전달되면, 억제되어야 할 노이즈 토큰들이 $\exp(0) = 1$ 의 가중치를 부여받아 과대평가되는 참사가 발생한다. 이는 셀프 어텐션 맵의 분포 자체를 완전히 붕괴시키며 트랜스포머 파이프라인 전체의 정보 엔트로피를 교란시킨다. 베이스 논문이 제시한 지수 감쇠 이론으로는 결코 대칭 및 비대칭 함수의 음수 도메인을 모사할 수 없음이 수학적으로 증명되는 순간이다.

4. 해결책 제시: Extended-Adaptive MBE 뉴런의 패러다임 전환

이러한 기존 MBE 뉴런의 절대적 양수 제약과 데드 뉴런 문제를 근원적으로 돌파하고, 완벽한 스파이킹 트랜스포머로의 변환을 완수하기 위해 사용자 제안 문서를 통해 고안된 모델이 바로 '**Extended-Adaptive MBE 뉴런**'이다. 이 뉴런 구조는 MBE의 지수 감쇠 철학을 유지하면서도, 딥러닝 최적화 이론의 정규화(Normalization) 기법과 신경세포의 생물학적 이형성(Heterogeneity)을 융합하여 동역학적 범위를 음수 차원까지 확장해 냈다.

4.1 스케일(γ) 및 시프트(β) 파라미터의 학습 변수화

Extended-Adaptive MBE 뉴런은 매개변수 업데이트 방식을 단순 비례 지수 감쇠에서 절편이 추가된 아핀(Affine) 지수 감쇠 형태로 재설계하였다. 베이스 논문에서 타겟 함수의 최댓값 등 고정된 상수로 취급되던 α 를 학습 가능한 스케일 변수(Learnable Scaling Parameter, γ 또는 $\alpha_{learnable}$)로 격상시키고, 여기에 편향을 의미하는 시프트 파라미터(β)를 추가 도입했다.

수정된 뉴런 파라미터 방정식은 다음과 같다:

$$V_{th}^{(n)}[t] = \alpha_{vth}^{(n)} \cdot \exp(-t/\tau^{(n)}) + \beta_{vth}^{(n)}$$

$$r^{(n)}[t] = \alpha_r^{(n)} \cdot \exp(-t/\tau^{(n)}) + \beta_r^{(n)}$$

$$d^{(n)}[t] = \alpha_d^{(n)} \cdot \exp(-t/\tau^{(n)}) + \beta_d^{(n)}$$

이 아핀 변환의 도입은 SNN 동역학에 혁명적인 변화를 가져온다. 학습 과정을 통해 시프트 파라미터 β_{vth} 가 음의 실수(Negative Real Number)로 유도될 수 있기 때문이다. 시간이 흐름에 따라 지수 함수 항이 0에 수렴하게 되면, 전체 임계값 $V_{th}[t]$ 의 궤적은 0을 관통하여 β_{vth} 가 형성한 음수 영역으로 하강하게 된다. 다시 앞서 실패했던 $u = -1.0$ 의 시나리오를 대입해 보자. 임계값이 지수 감쇠를 거쳐 음수 값인 -1.5 로 떨어지는 특정 타임스텝에 도달하면, $u[t](-1.0) \geq V_{th}[t](-1.5)$ 의 조건이 극적으로 충족된다. 헤비사이드 계단 함수는 비로소 1을 반환하며, 오랫동안 침묵하던 뉴런이 스파이크를 방출(Firing)하게 된다. 방출된 스파이크는 음수로 조정된 강도항(β_d 등에 의해 음수로 치환된 $d[t]$)과 결합하여 누적기에 더해지고, 결과적으로 타겟 함수가 요구하는 정확한 음수 실수값(예: -0.17)을 재구성해낸다. 이는

스파이크가 발현될 수 있는 물리적 무대를 음수 도메인으로 확장(Stage Expansion)한 수학적 패거이다.

4.2 분화 초기화(Differentiation Initialization)의 신경생물학적 정당성

수식적 확장만으로는 최적화 과정의 안정성을 담보하기 어렵다. 파라미터의 자유도가 높아지면 무작위 초기화 시 양수와 음수를 표현하려는 기저(Basis)들이 서로 충돌하는 상쇄 간섭(Catastrophic Cancellation)이 발생할 수 있다. 이를 방지하기 위해 Extended-Adaptive 뉴런은 '분화 초기화(Differentiation Initialization)' 전략을 도입했다.

이 전략은 포유류 시각 피질 망막의 양극 세포(Bipolar Cells) 거동을 모사한 것이다. 생물학적 망막은 빛이 증가할 때 반응하는 ON-중심 세포와 감소할 때 반응하는 OFF-중심 세포로 물리적으로 분화되어 양방향 신호를 에너지 효율적으로 인코딩한다. 본 모델은 기저 뉴런 집단의 절반은 양수 도메인을, 나머지 절반은 음수 도메인을 전담하도록 파라미터를 양극화하여 초기화한다.

- 양수 전담 기저: 학습 스케일 α 를 타겟 최댓값의 10% ($0.1 \times Target_{Max}$)로 초기화.
- 음수 전담 기저: α 를 ($-0.1 \times Target_{Max}$)로 대칭적으로 할당.

이러한 구조적 사전지식(Structural Prior)의 주입은 모델이 학습을 시작하기도 전에 신경망의 위상적 역할을 양분해 주며, 각 기저가 자신이 전담하는 부호 도메인 내에서만 지수 감쇠 곡선을 최적화하도록 유도한다. 결과적으로 훈련 수렴 속도가 극적으로 단축되고, 곡률이 심한 국소 구간에서도 전역적 최적점(Global Optimum)에 도달할 확률이 비약적으로 향상된다.

4.3 아키텍처 특성 비교 분석

아키텍처 특성	기본 MBE 뉴런 (베이스 논문, AAAI-26)	Extended-Adaptive MBE (제안 모델)	학술적 및 모델링 이점
임계값(V_{th}) 도메인	0 이하로 절대 하강 불가능 (수학적 제약)	정규화 기반 γ, β 변수에 의해 음수 영역 진입 가능	"무대 확장"을 통한 음수 입력에 대한 침묵(Dead Neuron) 현상 영구 해소
막전위 회복 메커니즘	단순 양수 차감 (음수 입력 발화 시 회복 불능)	α_r, β_r 을 통한 유동적 음수 역보정	폐순환 동역학 최적화로 연속적 스파이크 발화 보장
초기화 전략	타겟 최댓값 기반 고정 파라미터 및 무작위 획일 초기화	0.1 배율 기반의 양극성 양/음수 기저 분화 초기화	생물학적 ON/OFF 세포 모사 및 상쇄 간섭 방지를 통한 수렴 속도 최적화

위 표에서 보듯, Extended-Adaptive MBE 모델은 구조적으로 완벽한 비선형 활성화 공간 매핑을 달성하며, 이후 설명할 동적 에너지 모델 산출의 흔들림 없는 기준점이 된다.

5. 선형 연산(Linear Operation)의 알고리즘적 최적화와 실험적 증명

스파이킹 트랜스포머의 비선형 연산이 Extended-Adaptive MBE로 정확히 매핑된다 할지라도, 네트워크 연산량의 90% 이상을 차지하는 것은 선형 계층(Linear Layer)의 행렬 곱셈이다. MLP 연산을 훈련 없이(Training-Free) SNN으로 변환한 본 연구의 실험 일지에 따르면, 변환 초기에 정확도 손실은 0.00%로 완벽히 방어되었으나(ANN Acc 99.75%, SNN Acc 99.75%), 정작 가장 중요한 **에너지 절감률이 -421.67%로 나타나는 역설적인 상황**이 발생했다.

5.1 $O(K^2)$ 복잡도 폭발과 직접 근사의 오류

초기 실험의 실패 원인은 부동소수점 곱셈을 SNN 도메인으로 변환하는 과정의 비효율적 설계에 있었다. 기존 ANN에서 선형 연산은 $y_i = \sum_{j=1}^{In} W_{ij} \cdot x_j$ 로 정의된다. 초기 SNN 구현은 입력 x_j 를 MBE 뉴런 기반의 스파이크 시퀀스 $\sum_{t=1}^T \sum_{n=1}^N d_n[t] \cdot s_{j,n}[t]$ 로 변환한 뒤, 이를 매 타임스텝마다 가중치 W_{ij} 와 직접 곱하는 방식을 취했다. 나아가 어텐션 블록 내부 등에서 두 변수 x 와 y 를 스파이크 도메인에서 교차 곱셈할 때는 $\sum_i \sum_j (d_{x,i} \cdot d_{y,j}) \cdot (s_{x,i} \cdot s_{y,j})$ 형태로 모든 조합 공간을 탐색해야 했다. 스파이크 슬롯이 32개라면 매 데이터마다 $32 \times 32 = 1024$ 번의 상호작용이 발생하는 $O(K^2)$ 의 이차 복잡도 연산이 유발되었다. 이는 SNN이 ANN의 단일 MAC 연산(4.6 pJ)을 대체하기 위해 무려 161.7 번의 SOP 연산을 수행하게 만들어, 에너지 효율 지표가 파괴되는 결과를 초래했다.

5.2 W_{eff} 메커니즘: 상수 결합과 분배 법칙을 통한 최적화

이러한 연산 폭발을 해결하고 SNN의 진정한 순수 덧셈 기반(Addition-only) 효율성을 복구하기 위해 실험 연구진은 **유효 가중치(Effective Weight, W_{eff})** 최적화 기법을 도입하였다. 학습이 완료된 A2S 변환 SNN 모델에서, 함수의 원래 가중치인 W_{ij} 와 MBE 뉴런의 스파이크 강도 벡터 $d_n[t]$ 는 추론(Inference) 단계에서 값이 변하지 않는 **상수(Constant)** 이다. 따라서 수학적 분배 법칙을 적용하여 시그마(Σ) 내부의 식을 재조합할 수 있다.

1. **수식의 결합:** $y_i \approx \sum_{j=1}^{In} W_{ij} \cdot \left(\sum_{t=1}^T \sum_{n=1}^N d_n[t] \cdot s_{j,n}[t] \right)$
2. 상수인 가중치와 스파이크 강도를 묶어 새로운 상수로 정의한다. $W_{eff,i,j,n}[t] = W_{ij} \cdot d_n[t]$
3. **최종 도출된 SNN 선형 수식:** $y_i \approx \sum_{t=1}^T \sum_{n=1}^N \sum_{j=1}^{In} W_{eff,i,j,n}[t] \cdot s_{j,n}[t]$

이 W_{eff} 메커니즘의 핵심은 모델 로드(Load) 시점에 단 한 번 부동소수점 곱셈을 수행하여 메모리에 캐싱(Caching)해 둔다는 점이다.

5.3 이진 제어(Binary Control)로의 전환과 효율성 회복

수식이 개편됨에 따라 실제 하드웨어 혹은 시뮬레이터에서 작동하는 추론 방식은 근본적으로 변화한다. 이진 제어(Binary Control) 메커니즘을 통해 행렬 곱셈 연산이 조건부 분기문(IF 문)으로 완벽하게 대체된다.

스�파이크 값 $s_{j,n}[t]$ 는 구조적으로 오직 0 또는 1 만을 가진다. 따라서 $W_{eff} \cdot s$ 연산은 곱셈기가 전혀 필요 없는 단순한 누적기(Accumulator) 제어 신호로 변환된다.

- **만약 $s_{j,n}[t] == 1$ 이면:** 누적기에 캐싱된 W_{eff} 값을 더한다.

- 만약 $s_{j,n}[t] == 0$ 이면: 아무런 연산도 수행하지 않고 건너뛰다 (에너지 제로).

이는 연속된 부동소수점 곱셈(MAC)을 전력 소모가 극히 적은 순수 조건부 덧셈(SOP)으로 완전히 치환한 것이다. 또한 상호 곱셈 역시 분배법칙을 역이용하여 $(\sum s_{x,i} d_{x,i}) \cdot (\sum s_{y,j} d_{y,j})$ 형태로 결합함으로써, 복잡도를 $O(K^2)$ 에서 $O(K)$ 로 극적으로 낮추었다.

5.4 실험 일지 기반의 정량적 효율성 증명

알고리즘적 최적화 전후의 변화는 벤치마크 실험 결과를 통해 극명하게 드러난다. 복잡도를 낮추고 W_{eff} 를 적용한 후 진행된 MNIST 데이터셋 기반의 다층 퍼셉트론(MLP) 실험에서 SNN의 동적 연산 지표는 다음과 같이 급반전하였다.

측정 지표	최적화 전 SNN (Synthetic Data)	최적화 후 SNN (MNIST Data)
타임스텝 / 기저 수	T=16, N=8	T=8, N=4
ANN 대비 정확도 오차	0.00% (99.75% -> 99.75%)	0.67% Drop (98.13% -> 97.46%)
연산 비율 (SOP/MAC)	161.7 SOPs 당 1 MAC	2.6 SOPs 당 1 MAC
추정 에너지 절감률	-421.67% (악화)	+ 91.70% (극적 향상)

위 결과는 적절한 시프트/스케일 최적화와 가중치 선계산 기법이 결합될 때, SNN이 ANN 대비 비약적인 에너지 이점을 누릴 수 있음을 정량적으로 증명한다. MAC의 연산 횟수를 압도했던 SOP 발생량이 최적화 이후 MAC 대비 2.6배 수준으로 통제되었으며, 부동소수점 곱셈기의 배제 효과가 극대화되어 최종적으로 91.70%의 순수 에너지 절감이라는 쾌거를 이루어냈다. 이후 진행된 대규모 네트워크(GPU 테스트)에서도 여전히 65.65%의 강력한 에너지 절감 효율을 유지함이 확인되었다.

6. SNN과 ANN 구조 맞춤형 종합 동적 연산 에너지 측정 모델의 제안

본 연구의 최종 목적은 상기 입증된 하드웨어 및 수학적 이론을 융합하여, 트랜스포머를 비롯한 최신 모델들이 구동될 때 소모되는 에너지를 완벽하게 비교할 수 있는 '**종합 동적 연산 에너지 비율 (Comprehensive Dynamic Compute Efficiency Ratio, CDCER)**' 측정 모델을 공식화하는 데 있다. 사용자 요청에 따라, 본 모델은 칩의 물리적 설계에 의존적인 메모리 계층(L1/L2 Cache, DRAM 등)의 데이터 이동 비용을 제외하고, 순수한 논리 연산 블록(ALU, FPU)에서 소비되는 순수 동적 연산 에너지(Dynamic Compute Energy)만을 타겟으로 한다. 하드웨어 기준은 논문들에서 보편적으로 활용되는 Horowitz 45nm CMOS 공정의 에너지 상수 체계를 근간으로 하되, 무시되어 온 비선형 연산의 비용을 정확히 복원한다.

6.1 인공신경망(ANN)의 정확한 동적 에너지 Baseline 재정립

기존 문헌들은 ANN의 에너지를 도출할 때 $N_{MAC} \times 4.6$ pJ 만을 계산했다. 하지만 앞서 분석했듯, 트랜스포머의 비선형 모듈 안에는 덧셈, 곱셈뿐 아니라 막대한 전력을 소모하는 나눗

셈(DIV), 역제곱근(SQRT), 지수(EXP) 연산이 존재한다. 따라서, 특정 레이어 모듈(m)에서 ANN이 소모하는 동적 에너지 $E_{ANN}^{(m)}$ 은 다음과 같이 세분화되어야 한다.

$$E_{ANN}^{(m)} = \left(N_{MAC}^{(m)} \cdot E_{MAC} \right) + \left(N_{ADD}^{(m)} \cdot E_{FP_ADD} \right) + \left(N_{MULT}^{(m)} \cdot E_{FP_MULT} \right) + E_{Trans}^{(m)}$$

여기서 $E_{MAC} = 4.6$ pJ, $E_{FP_ADD} = 0.9$ pJ, $E_{FP_MULT} = 3.7$ pJ 이며, $E_{Trans}^{(m)}$ 는 초월함수 및 복잡 비선형 연산 에너지의 총합으로 다음과 같이 정의된다.

$$E_{Trans}^{(m)} = \left(N_{EXP}^{(m)} \cdot E_{EXP} \right) + \left(N_{DIV}^{(m)} \cdot E_{DIV} \right) + \left(N_{SQRT}^{(m)} \cdot E_{SQRT} \right)$$

디지털 논리회로 설계의 관례 및 부동소수점 유닛(FPU) 합성 결과들에 따르면, 지수 함수나 역제곱근을 도출하기 위한 반복 알고리즘(Taylor Series, Newton-Raphson)은 내부적으로 수십 개의 덧셈과 곱셈을 수반한다. 따라서 E_{DIV} 와 E_{SQRT} 는 대략 $10 \sim 15 \times E_{MAC}$ 수준의 에너지를, E_{EXP} 는 $15 \sim 20 \times E_{MAC}$ 수준의 에너지를 소모한다고 모델링하는 것이 타당하다. 이렇게 산출된 ANN의 에너지는 기존 대비 확연히 증가하게 되며, 이것이 곧 SNN이 대체하고 절감해야 할 '진짜' 목표 수치가 된다. 전체 네트워크의 ANN 에너지는 모든 모듈의 합산인 $E_{Total}^{ANN} = \sum E_{ANN}^{(m)}$ 으로 정의된다.

6.2 Extended-Adaptive MBE 스파이킹 네트워크의 동적 에너지 산출

Extended-Adaptive MBE 뉴런 기반의 SNN은 W_{eff} 최적화를 적용했으므로, 런타임 추론(Inference) 단계에서 부동소수점 곱셈과 초월함수 연산기(Divider, Exponentiator)를 하드웨어적으로 전혀 가동하지 않는다. 모든 연산은 스파이크 도착 여부에 따른 조건부 누적 덧셈(Accumulate)으로 치환된다. 따라서 SNN의 누적 덧셈 에너지 상수는 45nm 공정 기준 $E_{AC} = 0.9$ pJ 를 온전히 따른다.

그러나 정확한 측정을 위해서는 학습이 끝난 모델을 로딩할 때 1회 발생하는 사전 연산(Pre-computation) 비용과, 타임스텝(T) 및 발화율(Fr)에 종속되는 추론 비용을 분리하여 측정해야 한다.

1. 사전 연산 에너지 ($E_{PreCompute}^{SNN}$): 네트워크가 시작될 때 가중치 W 와 스파이크 기저 d_n 을 곱하여 W_{eff} 를 만드는 1회성 비용이다.

$$E_{PreCompute}^{SNN} = \sum_{l=1}^L \left(N_{Weights}^{(l)} \times N_{Bases} \times T \right) \cdot E_{FP_MULT}$$

2. 순수 추론 에너지 ($E_{Inference}^{SNN}$): 조건부 덧셈을 통해 선형 모듈과 비선형 MBE 근사 모듈을 구동하는 에너지이다. 레이어 l 의 발화율(스�파이크 밀도)을 $Fr^{(l)}$ 로 정의할 때, 연산량은 다음과 같이 계산된다.

$$E_{Inference}^{SNN} = \sum_{l=1}^L \left(N_{Neurons}^{(l)} \cdot Fr^{(l)} \cdot T \cdot N_{Bases} \right) \cdot E_{AC} + \sum_{n=1}^{N_{nonlinear}} SOP_{MBE_Approx}^{(n)} \cdot E_{AC}$$

위 수식에서 SOP_{MBE_Approx} 는 GELU나 Softmax 같은 복잡한 비선형 곡선을 Extended-Adaptive MBE 뉴런으로 근사할 때 방출되는 덧셈 연산의 총량을 의미한다.

최종 SNN 소비 에너지: 전체 배포 환경에서 모델이 K 번의 추론(Epochs/Samples)을 수행한다고 가정하면, 추론 1회당 발생하는 동적 에너지는 다음과 같이 배분된다.

$$E_{Total}^{SNN} = \frac{E_{PreCompute}^{SNN}}{K} + E_{Inference}^{SNN}$$

대규모 서비스 배포 시 K 는 무한대로 수렴하므로 사전 연산

비용은 0에 가까워지며, 네트워크는 순수하게 E_{AC} 로만 구동되는 극단의 효율을 달성하게 된다.

6.3 종합 효율성 비율 (CDCER) 공식화와 효용성

이를 통합하여 본 연구가 제시하는 최종 종합 동적 연산 에너지 효율 지표(Comprehensive Dynamic Compute Efficiency Ratio, CDCER)는 다음과 같다.

$$CDCER = 1 - \frac{E_{Total}^{SNN}}{E_{Total}^{ANN}} = 1 - \frac{\left(\frac{E_{PreCompute}^{SNN}}{K} + E_{Inference}^{SNN} \right)}{\sum E_{ANN}^{(m)}}$$

이 모델은 기존 논문들의 막연한 효율성 주장을 완벽히 검증할 수 있는 탁월한 잣대이다.

1. **비선형 오버헤드의 가시화:** 분모(E_{ANN})에 E_{DIV} , E_{SQRT} 등의 하드웨어 연산 비용을 명시적으로 포함함으로써, 트랜스포머 구조에서 ANN이 낭비하는 막대한 에너지를 정확히 산출한다.
2. **SNN의 숨겨진 비효율성 페널티 부과:** 분자(E_{SNN})에 무분별한 스파이크 상호작용으로 인해 발생할 수 있는 과도한 SOP 횟수를 투명하게 반영한다. 만약 W_{eff} 알고리즘을 사용하지 않아 발화율 통제에 실패한 SNN이라면 CDCER 수치는 즉각 마이너스(-)로 전환되며 설계의 오류를 경고한다.
3. **Extended-Adaptive MBE의 정당성 부여:** 음수 도메인을 완벽히 처리하면서도 추가적인 부동소수점 역산(FP inversion) 없이 오직 E_{AC} (0.9 pJ)만으로 활성화 함수를 근사해내는 제안 뉴런 모델의 가치를 수학적, 에너지적 관점에서 명확하게 입증한다.

7. 결론

거대 인공지능 시대에 스파이킹 신경망(SNN)이 진정한 초저전력 대안으로 자리매김하기 위해서는 높은 정확도 확보와 더불어 정밀하고 엄밀한 에너지 측정 표준이 확립되어야 한다. 기존의 많은 A2S 변환 논문들은 비전(CNN) 중심의 단순한 MAC/AC 연산 비율표(4.6 pJ vs 0.9 pJ)에 기대어 SNN의 에너지 이점을 과대 포장해 왔다. 이는 트랜스포머 아키텍처에 내재된 LayerNorm, Softmax, GELU 등에서 발생하는 지수, 역제곱근, 나눗셈 연산의 막대한 하드웨어 비용과 이를 스파이크로 근사할 때 폭증하는 2차 연산 복잡도를 완전히 외면한 방법론적 오류였다.

더불어, 최신 탐티어 학회(AAAI-26)에서 각광받은 기저 감쇠(MBE) 뉴런조차 수식에 내재된 절대적 양수 제약으로 인해 비선형 곡선의 음수 도메인 진입을 차단하는 '데드 뉴런(Dead Neuron)' 문제를 일으켰다. 이는 단순한 국소적 오차를 넘어 어텐션 확률 분포 전체의 엔트로피를 붕괴시키는 치명적 결함이다.

본 연구 보고서는 이러한 SNN 분야의 이론적, 구조적 난제들에 대한 궁극적 해결책을 제시하였다. 신경망의 동역학적 무대를 음수 공간까지 확장한 **Extended-Adaptive MBE 뉴런**은 스케일 및 시프트 파라미터의 학습 변수화와 망막 양극 세포에 착안한 분화 초기화 (Differentiation Initialization) 전략을 통해 완벽한 부호 표현력과 수렴 안정성을 이룩하였다. 또한, 훈련된 파라미터의 상수화를 이용한 W_{eff} **메커니즘**을 도입하여 선형 공간의 부동소수점 곱셈을 이진 제어 기반의 $O(K)$ 조건부 덧셈으로 치환함으로써, 초기 실험에서 드러난 연

산 폭발(-421.67% 에너지 손실)을 제어하고 91.70%의 순수 에너지 절감이라는 실증적 대역전을 완성하였다.

최종적으로 본 연구가 수립한 종합 동적 연산 에너지 측정 모델(CDCER)은 기존의 편향된 지표를 대체할 새로운 이정표이다. ANN의 비선형 초월함수 하드웨어 오버헤드와 SNN의 사전 연산 및 발화율 기반 누적 덧셈 비용을 순수 동적 연산의 관점에서 날낱이 해체하여 재구성한 이 모델은, 향후 스파이킹 트랜스포머 연구가 나아가야 할 객관적이고 과학적인 하드웨어-알고리즘 통합 검증 프레임워크로 기능할 것이다. 딥러닝과 뉴로모픽 공학의 진정한 교집합은 바로 이토록 정교한 수학적 통찰과 엄정한 측정 기준 위에서만 피어날 수 있다.